FASE A — DISEÑO DE LA BODEGA DE DATOS

1. Introducción

El presente documento describe el diseño de una bodega de datos dimensional construida a partir del conjunto de datos de siniestralidad vial en Cali correspondiente al periodo 2016–2024. El propósito de este diseño es organizar la información disponible en una estructura adecuada para su posterior procesamiento, almacenamiento y análisis, facilitando la ejecución de consultas orientadas a estudiar el comportamiento de los eventos de siniestralidad.

Para la construcción de la bodega se propone un modelo dimensional de tipo estrella, compuesto por una tabla central de hechos denominada Hecho_Siniestralidad y seis tablas de dimensión: Dim_Fecha, Dim_Ubicacion, Dim_Tipo_Accidente, Dim_Tipo_Confirmado, Dim_Medio_Reporte y Dim_Vehiculos_Implicados.

La elección de este modelo busca mantener una estructura comprensible y eficiente para el análisis, concentrando los datos cuantitativos y las referencias a las dimensiones en una tabla de hechos central, mientras que las características descriptivas de cada evento se almacenan en dimensiones independientes.

2. Descripción del conjunto de datos

El conjunto de datos utilizado contiene **371.003 registros y 10 atributos** relacionados con reportes de siniestralidad vial registrados entre los años 2016 y 2024.

La información disponible incluye el código del reporte, la fecha, la clasificación del evento confirmado, la dirección del reporte, la clase de accidente, una clasificación detallada del evento, el medio mediante el cual fue reportado, el número de vehículos involucrados y los tipos de vehículos implicados.

Los atributos presentes en el archivo fuente son:

- Código
- Fecha
- Tipo confirmado
- Dirección reporte
- Tipo clase de accidente
- Tipo clase de accidente.1

- Tipo confirmado.1
- Medio de reporte
- Numero vehículos
- Tipo de vehículos implicados

Durante la exploración inicial del conjunto de datos se identifican aspectos que deberán ser tratados posteriormente durante el proceso ETL, tales como valores faltantes o representados mediante caracteres especiales, diferencias en la escritura de algunas categorías y la presencia de atributos aparentemente duplicados. Sin embargo, estos procesos de limpieza y normalización no forman parte del alcance de la presente fase, cuyo propósito corresponde al diseño conceptual y lógico de la bodega.

3. Selección del modelo dimensional

Para la bodega de datos se seleccionó un **modelo estrella**.

Este modelo se caracteriza por disponer una tabla de hechos central relacionada directamente con diferentes tablas de dimensión. Su utilización resulta apropiada para el conjunto de datos seleccionado debido a que cada reporte de siniestralidad puede ser analizado desde diferentes perspectivas, como el tiempo, la ubicación, el tipo de accidente, la clasificación del evento, el medio de reporte y los vehículos implicados.

Se prefirió el modelo estrella frente a un modelo copo de nieve con el propósito de mantener una estructura relativamente simple, reducir la cantidad de relaciones necesarias para realizar consultas analíticas y facilitar las etapas posteriores de extracción, transformación y carga de los datos.

Asimismo, el modelo propuesto conserva una separación clara entre los eventos registrados y sus características descriptivas. De esta manera, la tabla de hechos representa los reportes individuales de siniestralidad, mientras que las dimensiones proporcionan el contexto necesario para analizarlos.

4. Definición de la granularidad

La **granularidad de la tabla de hechos** se establece en el nivel de un reporte individual de siniestralidad vial.

Por lo tanto:

Cada registro de Hecho_Siniestralidad representa un reporte individual de siniestralidad vial identificado mediante su código y asociado con una fecha, ubicación, tipo de accidente, clasificación, medio de reporte y combinación de vehículos implicados.

La elección de esta granularidad permite conservar el máximo nivel de detalle proporcionado por el conjunto de datos original. A partir de este nivel será posible realizar posteriormente agregaciones y análisis con diferentes grados de detalle sin perder la identificación individual de los eventos registrados.

5. Tabla de hechos

5.1. Hecho_Siniestralidad

La tabla Hecho_Siniestralidad constituye el elemento central del modelo dimensional y almacena cada evento individual registrado en el conjunto de datos.

Granularidad

Cada fila representa **un reporte individual de siniestralidad vial**.

Estructura

Atributo: id_siniestro

Tipo de dato propuesto: BIGINIT

Rol: PK

Descripción: Identificador interno único del registro de la tabla de hechos.

Atributo: código_reporte

Tipo de dato propuesto: VARCHAR

Rol: Atributo

Descripción: Código original que identifica el reporte en el conjunto de datos fuente.

Atributo: id_fecha

Tipo de dato propuesto: INT

Rol: FK

Descripción: Referencia a Dim_Fecha.

Atributo: id_ubicacion

Tipo de dato propuesto: INT

Rol: FK

Descripción: Referencia a Dim_Ubicacion.

Atributo: id_tipo_accidente

Tipo de dato propuesto: INT

Rol: FK

Descripción: Referencia a Dim_Tipo_Accidente.

Atributo: id_tipo_confirmado

Tipo de dato propuesto: INT

Rol: FK

Descripción: Referencia a Dim_Tipo_Confirmado.

Atributo: id_medio_reporte

Tipo de dato propuesto: INT

Rol: FK

Descripción: Referencia a Dim_Medio_Reporte.

Atributo: id_vehiculos_implicados

Tipo de dato propuesto: INT

Rol: FK

Descripción: Referencia a Dim_Vehiculos_Implicados.

Atributo: numero_vehiculos

Tipo de dato propuesto: INT

Rol: Medida

Descripción: Cantidad de vehículos involucrados en el reporte de siniestralidad.

Justificación

La tabla Hecho_Siniestralidad se diseñó para centralizar los eventos registrados y establecer sus relaciones con las diferentes perspectivas de análisis representadas por las dimensiones.

El atributo numero_vehiculos se conserva en esta tabla debido a su naturaleza cuantitativa. Su ubicación como medida permitirá posteriormente realizar operaciones de agregación, como sumas, promedios, mínimos o máximos, así como comparar la cantidad de vehículos involucrados según diferentes características de los eventos.

Por otra parte, codigo_reporte conserva el identificador proveniente del conjunto de datos original, mientras que id_siniestro funciona como identificador interno de la tabla de hechos. Las claves foráneas permiten relacionar cada reporte con sus características descriptivas sin necesidad de repetir dicha información dentro de la tabla central.

6. Tablas de dimensión

6.1. Dim_Fecha

La dimensión Dim_Fecha representa el componente temporal asociado con los eventos de siniestralidad.

Granularidad

Cada registro representa **una fecha calendario única**.

Atributos

Atributo: id_fecha

Tipo de dato propuesto: INT

Rol: PK

Descripción: Clave subrogada que identifica de manera única cada registro de la dimensión.

Atributo: fecha

Tipo de dato propuesto: DATE

Rol: Atributo descriptivo

Descripción: Fecha completa asociada al evento de siniestralidad.

Atributo: dia

Tipo de dato propuesto: INT

Rol: Atributo descriptivo

Descripción: Día del mes correspondiente a la fecha del evento.

Atributo: mes

Tipo de dato propuesto: INT

Rol: Atributo descriptivo

Descripción: Número del mes correspondiente a la fecha del evento.

Atributo: nombre_mes

Tipo de dato propuesto: VARCHAR

Rol: Atributo descriptivo

Descripción: Nombre del mes correspondiente a la fecha del evento.

Atributo: trimestre

Tipo de dato propuesto: INT

Rol: Atributo descriptivo

Descripción: Trimestre del año al cual pertenece la fecha.

Atributo: anio

Tipo de dato propuesto: INT

Rol: Atributo descriptivo

Descripción: Año correspondiente a la fecha del evento.

Justificación

La creación de Dim_Fecha permite analizar la siniestralidad desde una perspectiva temporal y realizar agregaciones a diferentes niveles de detalle.

Aunque el conjunto de datos original proporciona una fecha completa, separar sus componentes facilita la realización de consultas por día, mes, trimestre o año sin necesidad de calcular dichos valores repetidamente durante cada análisis.

Los atributos dia, mes, nombre_mes, trimestre y anio serán derivados de la fecha original durante el proceso de transformación de los datos.

6.2. Dim_Ubicacion

La dimensión Dim_Ubicacion representa la información disponible acerca del lugar en el cual fue reportado el evento.

Granularidad

Cada registro representa **una dirección de reporte única**.

Atributos

Atributo: id_ubicacion

Tipo de dato propuesto: INT

Rol: PK

Descripción: Clave subrogada que identifica de manera única cada ubicación registrada.

Atributo: direccion_reporte

Tipo de dato propuesto: VARCHAR

Rol: Atributo descriptivo

Descripción: Dirección asociada al reporte de siniestralidad.

Justificación

La creación de Dim_Ubicacion proporciona el componente espacial disponible para el análisis de los eventos de siniestralidad.

La separación de las direcciones en una dimensión permite asociar múltiples eventos con una misma ubicación y posibilita posteriormente analizar la frecuencia de reportes según las direcciones registradas.

Se decidió conservar únicamente direccion_reporte debido a que corresponde a la información geográfica proporcionada directamente por la fuente. No se incorporan atributos como barrio, comuna, coordenadas geográficas u otras divisiones espaciales debido a que estos no se encuentran disponibles explícitamente en el conjunto de datos original.

6.3. Dim_Tipo_Accidente

Esta dimensión representa la clasificación de los eventos según la clase de accidente registrada.

Granularidad

Cada registro representa **un tipo de accidente único**.

Atributos

Atributo: id_tipo_accidente

Tipo de dato propuesto: INT

Rol: PK

Descripción: Clave subrogada que identifica de manera única cada tipo de accidente.

Atributo: tipo_accidente

Tipo de dato propuesto: VARCHAR

Rol: Atributo descriptivo

Descripción: Categoría correspondiente a la clase de accidente registrada.

Justificación

La existencia de Dim_Tipo_Accidente permite clasificar los reportes de acuerdo con la naturaleza del accidente y facilita la comparación entre las diferentes categorías existentes.

Su incorporación permitirá posteriormente desarrollar análisis relacionados con la frecuencia de cada tipo de accidente, su comportamiento a través del tiempo, el número de vehículos involucrados y su relación con las demás características disponibles.

El conjunto de datos contiene los atributos Tipo clase de accidente y Tipo clase de accidente.1. Debido a su aparente correspondencia, durante el proceso ETL deberá verificarse su equivalencia antes de eliminar cualquier información. El diseño

propone una clasificación consolidada denominada tipo_accidente, evitando mantener información redundante cuando se confirme dicha equivalencia.

6.4. Dim_Tipo_Confirmado

La dimensión Dim_Tipo_Confirmado representa la clasificación general y detallada asociada con el resultado confirmado del reporte.

Granularidad

Cada registro representa **una combinación única entre una clasificación general y su correspondiente clasificación detallada**.

Atributos

Atributo: id_tipo_confirmado

Tipo de dato propuesto: INT

Rol: PK

Descripción: Clave subrogada que identifica de manera única cada combinación de clasificación general y detallada.

Atributo: tipo_confirmado

Tipo de dato propuesto: VARCHAR

Rol: Atributo descriptivo

Descripción: Clasificación general correspondiente al resultado confirmado del reporte.

Atributo: detalle_confirmado

Tipo de dato propuesto: VARCHAR

Rol: Atributo descriptivo

Descripción: Clasificación específica o detallada asociada al resultado del reporte.

Justificación

El conjunto de datos contiene los atributos Tipo confirmado y Tipo confirmado.1, los cuales proporcionan información relacionada con la clasificación del evento.

Se propone integrarlos dentro de una misma dimensión debido a su relación semántica. El atributo tipo_confirmado conserva la clasificación general, mientras que detalle_confirmado representa el nivel específico disponible en la fuente.

Esta estructura permite realizar posteriormente análisis tanto desde una clasificación general como desde un nivel de mayor detalle, sin incrementar innecesariamente la cantidad de dimensiones del modelo.

6.5. Dim_Medio_Reporte

La dimensión Dim_Medio_Reporte representa el canal mediante el cual fue registrado o recibido cada reporte.

Granularidad

Cada registro representa **un medio de reporte único**.

Atributos

Atributo: id_medio_reporte

Tipo de dato propuesto: INT

Rol: PK

Descripción: Clave subrogada que identifica de manera única cada medio de reporte.

Atributo: medio_reporte

Tipo de dato propuesto: VARCHAR

Rol: Atributo descriptivo

Descripción: Medio utilizado para realizar, transmitir o recibir el reporte de siniestralidad.

Justificación

La creación de Dim_Medio_Reporte permite clasificar los eventos según el canal mediante el cual fueron reportados y estudiar posteriormente la participación de los diferentes medios registrados en el conjunto de datos.

Su separación de la tabla de hechos evita repetir las mismas cadenas de texto para una gran cantidad de registros y proporciona una estructura consistente para realizar agrupaciones y comparaciones.

Durante el proceso ETL será necesario normalizar los valores correspondientes a esta variable para evitar que diferencias de escritura, caracteres especiales, espacios o uso de mayúsculas generen categorías distintas para un mismo medio de reporte.

6.6. Dim_Vehiculos_Implicados

La dimensión Dim_Vehiculos_Implicados representa los tipos o combinaciones de vehículos asociados con cada reporte de siniestralidad.

Granularidad

Cada registro representa **una combinación única de tipos de vehículos implicados en un evento**.

Atributos

Atributo: id_vehiculos_implicados

Tipo de dato propuesto: INT

Rol: PK

Descripción: Clave subrogada que identifica de manera única cada combinación de tipos de vehículos.

Atributo: tipos_vehiculos

Tipo de dato propuesto: VARCHAR

Rol: Atributo descriptivo

Descripción: Tipo o combinación de tipos de vehículos implicados en el reporte.

Justificación

El atributo Tipo de vehículos implicados presenta una característica particular debido a que un mismo reporte puede involucrar uno o varios vehículos y, en consecuencia, diferentes combinaciones de tipos de vehículos.

Una alternativa de diseño sería separar individualmente los vehículos y establecer una relación de muchos a muchos mediante una tabla intermedia. Sin embargo, para el alcance del presente proyecto se propone conservar cada combinación normalizada como un miembro independiente de la dimensión.

Esta decisión permite preservar la información proporcionada por la fuente original y, al mismo tiempo, mantener una estructura sencilla para el proceso ETL y las consultas analíticas posteriores.

La cantidad de vehículos involucrados no se almacena dentro de esta dimensión, debido a que dicha información corresponde a una variable cuantitativa independiente. Por esta razón, numero_vehiculos se mantiene como medida dentro de Hecho_Siniestralidad, mientras que Dim_Vehiculos_Implicados se limita a describir los tipos de vehículos relacionados con el evento.

7. Uso de claves subrogadas

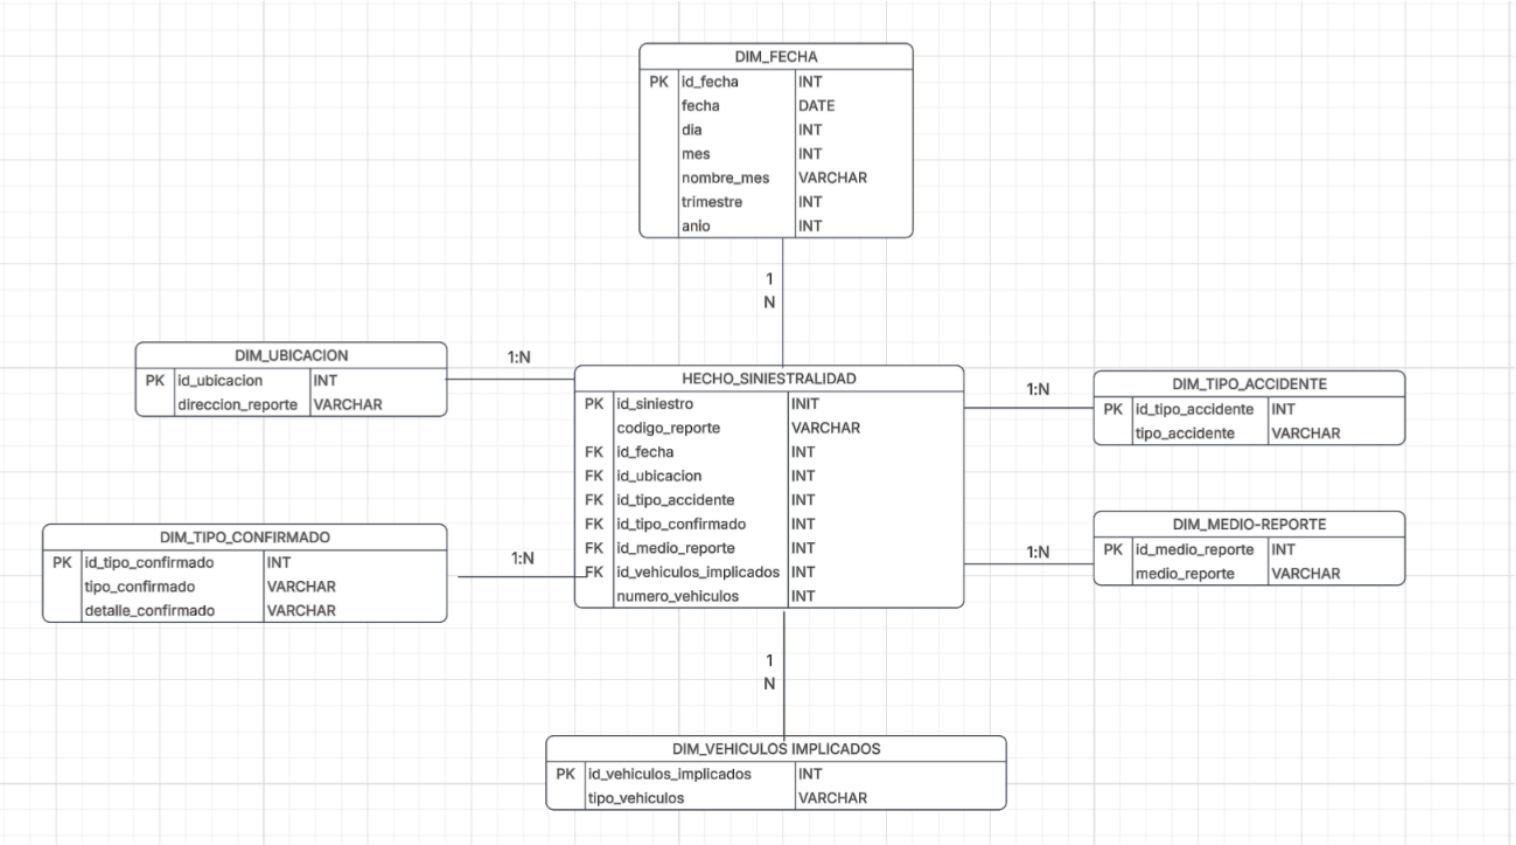
Las tablas de dimensión utilizarán **claves subrogadas**, representadas mediante identificadores enteros generados durante el proceso ETL.

Estas claves no corresponden necesariamente a atributos existentes en el conjunto de datos original. Su propósito es proporcionar identificadores internos simples y consistentes para establecer las relaciones entre la tabla de hechos y las diferentes dimensiones.

Por ejemplo, en lugar de almacenar repetidamente el texto correspondiente a un determinado medio de reporte dentro de Hecho_Siniestralidad, la tabla central almacenará id_medio_reporte, mientras que su descripción estará disponible en Dim_Medio_Reporte.

Este enfoque permite mantener separadas las características descriptivas de los eventos y las relaciones internas utilizadas por la bodega, además de facilitar la generación y administración de dichas relaciones durante el proceso ETL.

8. Diagrama del modelo dimensional



Link: https://lucid.app/lucidchart/07576dcc-023a-43a9-bd06-1e9a2c23a9f2/edit?viewport_loc=-758%2C-467%2C2385%2C1934%2C0_0&invitationId=inv_68a4ef67-c18d-477f-881d-1ba7d99092e3

El modelo dimensional propuesto está compuesto por Hecho_Siniestralidad como tabla central y seis dimensiones relacionadas directamente con ella:

- Dim_Fecha
- Dim_Ubicacion
- Dim_Tipo_Accidente
- Dim_Tipo_Confirmado
- Dim_Medio_Reporte

- Dim_Vehiculos_Implicados

Las relaciones entre las dimensiones y la tabla de hechos corresponden a relaciones **uno a muchos (1)**. Un registro de una dimensión puede estar asociado con múltiples eventos de siniestralidad, mientras que cada registro de Hecho_Siniestralidad referencia un único registro de cada dimensión.

Por ejemplo, una misma fecha puede estar relacionada con múltiples reportes de siniestralidad. De igual forma, un determinado tipo de accidente puede presentarse en múltiples eventos. Las claves foráneas almacenadas en la tabla de hechos permiten establecer estas relaciones.

9. Resumen de granularidades

Hecho_Siniestralidad: cada registro representa un reporte individual de siniestralidad vial.

Dim_Fecha: cada registro representa una fecha calendario única.

Dim_Ubicacion: cada registro representa una dirección de reporte única.

Dim_Tipo_Accidente: cada registro representa un tipo de accidente único.

Dim_Tipo_Confirmado: cada registro representa una combinación única entre una clasificación general y su clasificación detallada.

Dim_Medio_Reporte: cada registro representa un medio de reporte único.

Dim_Vehiculos_Implicados: cada registro representa una combinación única de tipos de vehículos implicados.

10. Consideraciones para las fases posteriores

El modelo dimensional fue diseñado considerando su utilización durante las fases posteriores del proyecto. La estructura propuesta permitirá que durante el proceso ETL se realicen las operaciones de limpieza y transformación necesarias, se generen las claves subrogadas y posteriormente se carguen los registros en las respectivas tablas.

La separación de la información mediante dimensiones también facilitará la formulación de consultas analíticas desde diferentes perspectivas y permitirá combinar criterios temporales, espaciales y categóricos.

Entre los posibles análisis que podrán realizarse posteriormente se encuentran la evolución temporal de la cantidad de reportes, la distribución de los tipos de accidente, la comparación del número de vehículos involucrados según las características de los eventos, la frecuencia de las diferentes combinaciones de vehículos y la participación de los distintos medios de reporte.

Estos ejemplos representan posibilidades de análisis derivadas de la estructura propuesta y no constituyen todavía resultados o conclusiones sobre el comportamiento de los datos.

11. Conclusión

El diseño propuesto organiza la información de siniestralidad vial mediante un modelo dimensional de tipo estrella, conformado por Hecho_Siniestralidad como tabla central y seis dimensiones encargadas de proporcionar los principales contextos descriptivos disponibles en el conjunto de datos.

La granularidad seleccionada conserva cada reporte individual como unidad fundamental de análisis, lo que permite realizar posteriormente diferentes niveles de agregación sin perder el detalle proporcionado por la fuente original.

La separación entre hechos y dimensiones busca facilitar la comprensión del modelo, reducir la repetición de información descriptiva y proporcionar una estructura apropiada para las etapas posteriores de extracción, transformación y carga, consultas SQL y análisis de datos.

Finalmente, el diseño mantiene los atributos relevantes proporcionados por la fuente y evita incorporar información que no se encuentre disponible en el conjunto de datos original. De esta manera, se obtiene una estructura suficientemente sencilla para su implementación y, al mismo tiempo, adecuada para desarrollar los análisis requeridos en las fases posteriores del proyecto.