Siniestralidad vial en Cali, 2016-2024

Informe del Proyecto 1 - Bodega de datos, ETL y análisis descriptivo (RA1)
Introducción a la ciencia de los datos - Prof. Héctor Fabio Ocampo Arbeláez
Grupo DatosSinCiencia –
Integrantes:
Jesus Ediber Arenas Guzman - 2266066
Juan Jose Guzman Camacho - 2380403
Natalia Martinez Castañeda - 2380414
Juan Pablo Rodriguez Gutierrez - 2380422
Juan Jose Wallens Serna - 2380556

1. Contexto y preguntas de negocio

El proyecto construye una bodega de datos dimensional sobre el registro de reportes de siniestralidad vial de Cali entre el 1 de enero de 2016 y el 2 de noviembre de 2024. La fuente es un CSV crudo (separado por «;», codificación latin-1) con 371.003 filas; tras descartar 1 fila vacía y 4 duplicados exactos quedan **370.998 reportes**, cada uno con fecha, dirección, tipo de accidente, tipo confirmado, medio de reporte, tipos de vehículos implicados y número de vehículos.

La unidad de análisis es el **reporte** y no el accidente: como se verá en el hallazgo 2, la mayoría de las filas son reportes negativos o sin tipo. Las preguntas de negocio que guían el análisis son:

- **P1.** ¿Cómo evolucionó el volumen de reportes entre 2016 y 2024 y qué tan comparable es esa serie? (Consulta 2)
- **P2.** ¿Qué parte de los reportes corresponde realmente a un accidente y de qué tipo? (Consulta 1)
- **P3.** ¿Es comparable el campo «medio de reporte» entre años? (Consultas 6 y 2)
- **P4.** ¿Qué combinaciones de vehículos aparecen con más frecuencia y cuánto pesa la motocicleta? (Consulta 5)

La Fase C plantea seis consultas SQL; este informe desarrolla las cuatro que sustentan los hallazgos. Las ocho visualizaciones completas, con su insight, están en *fase_d_visualizaciones.ipynb*.

Resumen de hallazgos. (1) La serie de reportes se parte en dos regímenes de registro y no muestra una tendencia gradual: la caída de 81 % entre 2016 y 2024 debe leerse como un cambio de cobertura. (2) Solo 1 de cada 9 reportes es un accidente con tipo registrado, y entre ellos el choque concentra tres de cada cuatro. (3) La motocicleta interviene en al menos el 36 % de los reportes que informan el número de vehículos.

2. Diagrama de la bodega y pipeline ETL

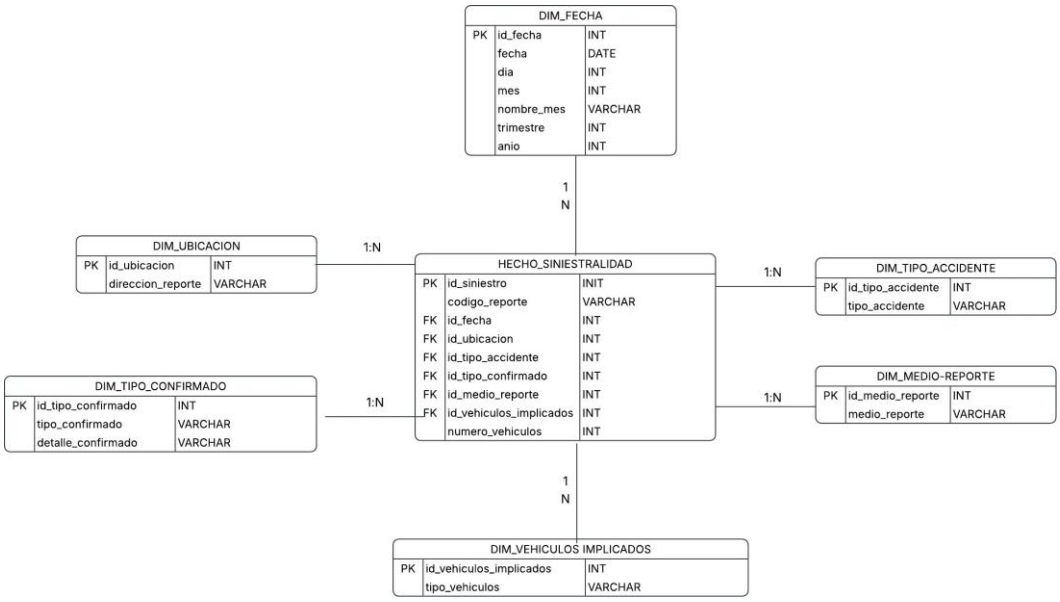


Figura A. Modelo estrella: una tabla de hechos y seis dimensiones, todas con clave subrogada entera.

Granularidad. Una fila de *hecho_siniestralidad* es un reporte individual, identificado por su código. La única medida es *numero_vehiculos*, que llega nula en el 52,4 % de los reportes y se carga sin imputar. Cada dimensión incluye una fila *id = -1* («DESCONOCIDO») para que el hecho nunca tenga una clave foránea nula.

Tabla	Filas	Qué contiene
hecho_siniestralidad	370.998	1 reporte por fila; 6 FK NOT NULL con índice; medida numero_vehiculos
dim_fecha	3.230	fecha, año, mes, trimestre, día de la semana, fin de semana
dim_ubicacion	59.349	dirección normalizada (texto libre)
dim_tipo_accidente	10	tipo de accidente, con «SIN ACCIDENTE (NEGATIVO)» y «NO APLICA»
dim_tipo_confirmado	38	clasificación general y detalle, con «SIN DETALLE»
dim_medio_reporte	11	medio de reporte (CAD 123, Telefónico 127, Radio, ...)
dim_vehiculos_implicados	735	combinación canónica de tipos de vehículo y banderas de motocicleta

Pipeline ETL (*fase_b_etl.ipynb*, un solo Restart & Run All):

- **Extracción:** lectura del CSV crudo con pandas, con aviso claro si el archivo no está.
- **Transformación:** se descarta 1 fila vacía y se eliminan 4 duplicados exactos; un diccionario de 12 reglas repara 84.073 celdas con caracteres dañados; 5 celdas de texto libre con datos personales se remapean a «OTRO»; se generan claves subrogadas y se convierten los tipos.
- **Carga:** escritura transaccional a PostgreSQL con SQLAlchemy y *DATABASE_URL* de *.env*, con mensajes de error claros. Después de cargar se verifican las claves primarias, las seis filas centinela y que no queden claves huérfanas.

3. Hallazgos clave

Hallazgo 1 - La serie se parte en dos regímenes de registro, no en una tendencia

Los reportes pasan de 64.323 en 2016 a 12.080 en 2024 (-81 %), pero la caída no es gradual. Entre 2016 y 2019 el volumen trimestral se mantiene entre unos 13.900 y 18.100 reportes; en 2020-T2 cae a unos 4.200 (cerca de -67 % en un solo trimestre) y desde entonces sigue bajando hasta unos 3.500 en 2024-T3, con otra caída fuerte en 2023 (-39,9 %). De los 35 trimestres completos, 17 están entre 12.600 y 18.100 y 18 por debajo de 9.300; ninguno queda en medio, de modo que la media (aprox. 10.600) no describe ningún trimestre real.



Figura 1. Reportes por trimestre, 2016-2024 (Consulta 2). El último punto es parcial: los datos terminan el 02-11-2024.

El campo «medio de reporte» refuerza la lectura (Figura 2): hasta 2020 prácticamente el 100 % de los reportes no lo trae (99,5 % en 2016) y solo desde 2021 empieza a llenarse, con Telefónico 127, CAD 123 y CAT 127 como medios predominantes en 2022, 2023 y 2024. Ambos cambios ocurren en la misma ventana, lo que apunta a un cambio en el sistema o la cobertura del registro y no a una mejora de la seguridad vial.

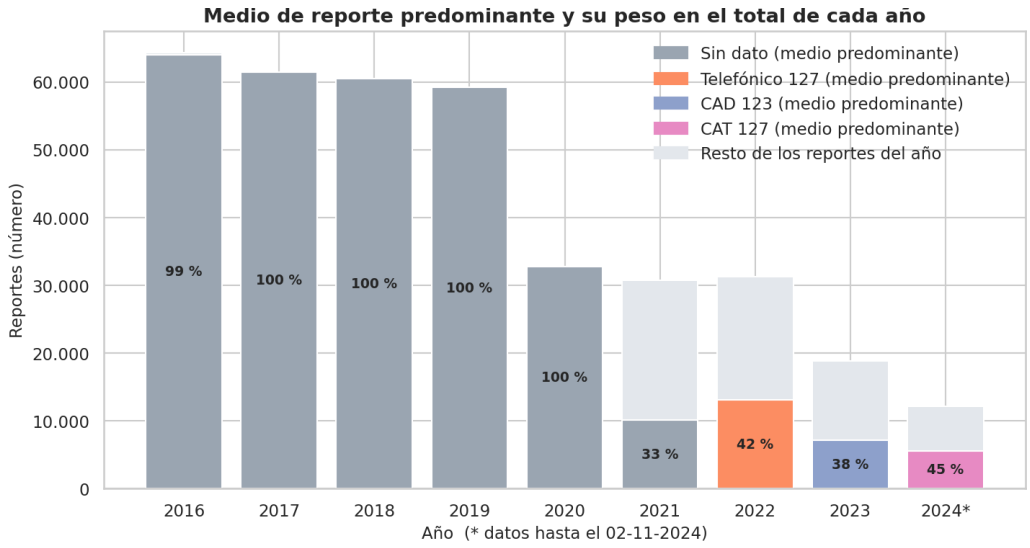


Figura 2. Medio de reporte predominante y su peso en el total de cada año (Consultas 6 y 2).

Hallazgo 2 - Solo 1 de cada 9 reportes es un accidente con tipo; tres de cada cuatro de esos son choques

De los 370.998 reportes, 227.937 (61,4 %) son reportes negativos sin accidente, 97.316 (26,2 %) no tienen tipo de accidente y 2.885 (0,8 %) figuran como «No aplica». Solo 42.860 (11,6 %) corresponden a un accidente con tipo registrado (Figura 3).

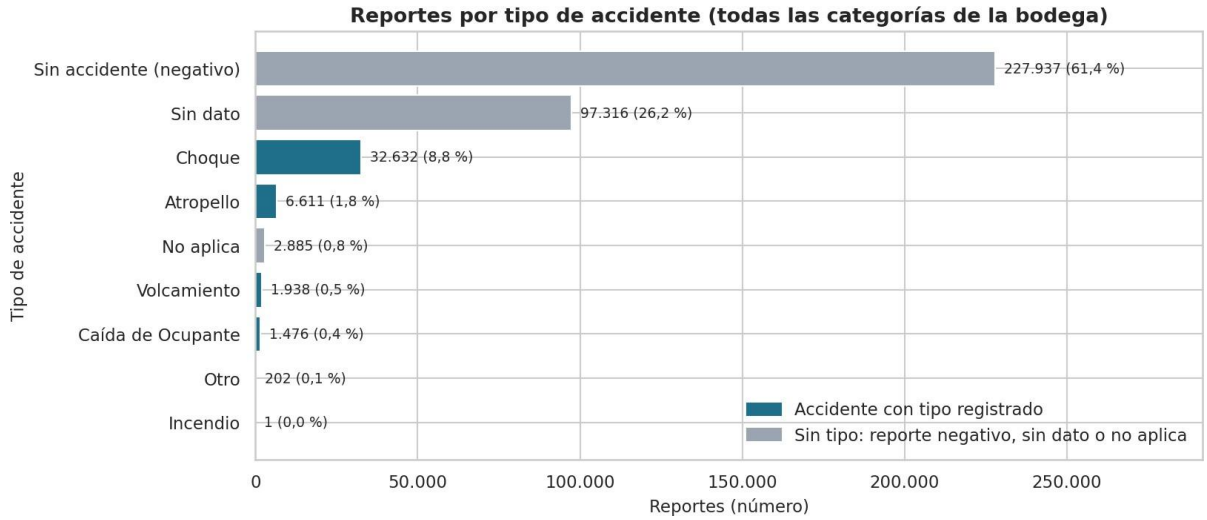


Figura 3. Reportes por tipo de accidente, todas las categorías (Consulta 1). En gris, las categorías sin tipo.

Entre los accidentes tipificados, el choque concentra el 76,1 % (32.632), el atropello el 15,4 % (6.611), y el volcamiento y la caída de ocupante suman 7,9 % (Figura 4). La implicación de negocio es priorizar la prevención de choques, que cubren tres de cada cuatro eventos tipificados, sin perder de vista el atropello por involucrar a peatones. Además, cualquier cifra de «siniestros» calculada sobre todas las filas sobreestima los accidentes cerca de nueve veces.

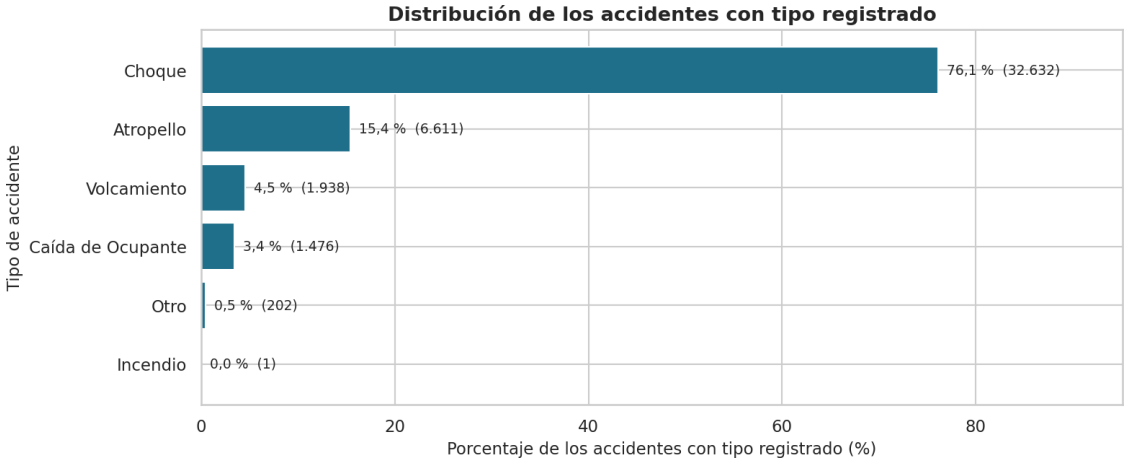


Figura 4. Distribución de los accidentes con tipo registrado (Consulta 1, sin categorías centinela).

Hallazgo 3 - La motocicleta interviene en más de un tercio de los reportes con vehículos informados

Solo 176.577 reportes (47,6 %) informan el número de vehículos. Entre ellos, el automóvil solo (50.846) y la combinación automóvil + motocicleta (37.242) reúnen el 49,9 %, y las combinaciones que incluyen motocicleta suman al menos 62.920 reportes (35,6 %): automóvil + motocicleta, motocicleta sola (21.507), camioneta + motocicleta (3.078) y camión + motocicleta (1.093) (Figura 5).

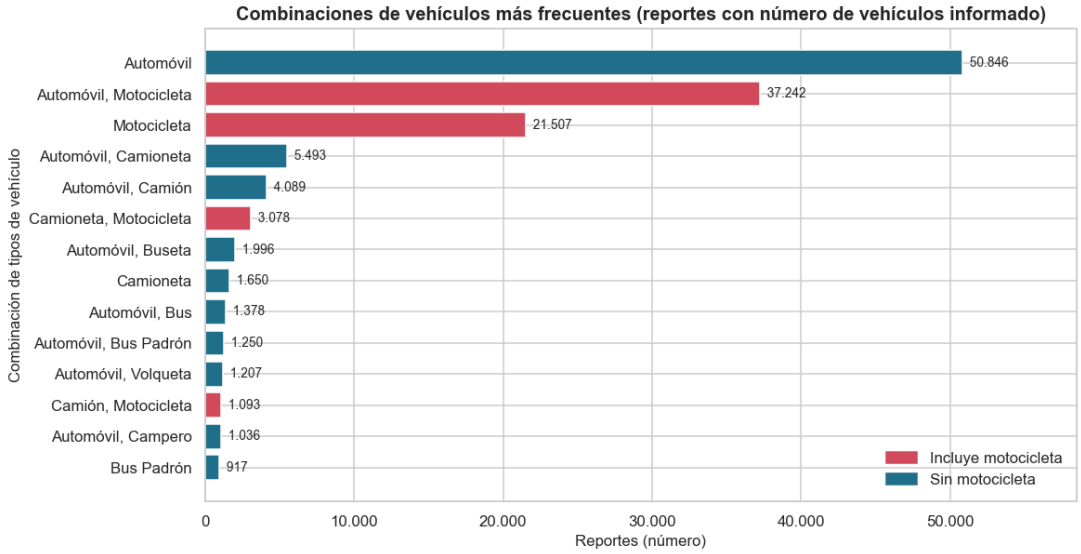


Figura 5. Combinaciones de vehículos más frecuentes (Consulta 5). En rojo, las que incluyen motocicleta.

La Figura 6 muestra una relación casi lineal (r = 0,99) entre el promedio de vehículos y la proporción de eventos multivehículo: todas las combinaciones con dos o más tipos de vehículo llegan al 100 %, mientras que la motocicleta sola lo es en 65,4 % y el bus padrón en 56,0 %. Parte de esta relación es mecánica (dos tipos distintos implican al menos dos vehículos), por lo que la señal útil está en los tipos únicos: la motocicleta es el vehículo que más a menudo aparece involucrado en eventos de un solo vehículo entre los de alto volumen.

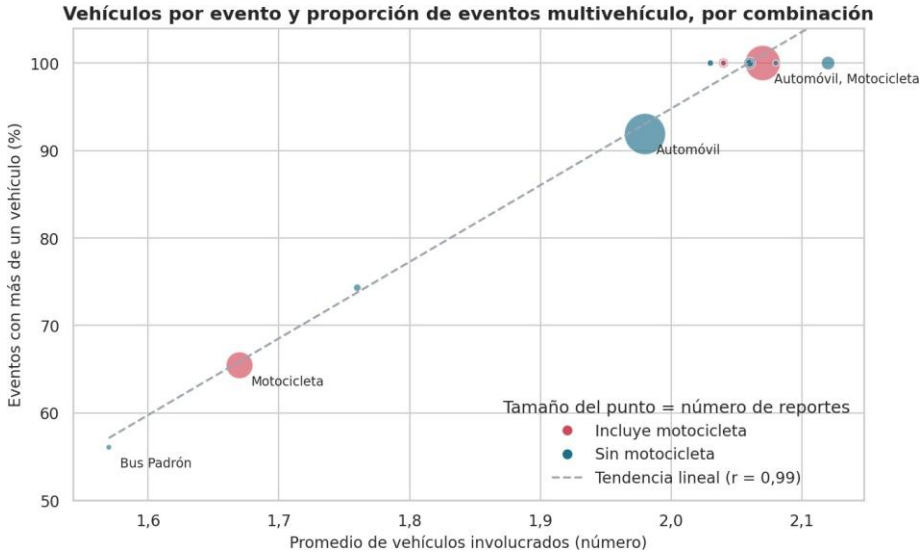


Figura 6. Promedio de vehículos vs. proporción de eventos multivehículo por combinación (Consulta 5).

4. Limitaciones y próximos pasos

Limitaciones

- **2024 está incompleto:** los datos llegan al 2 de noviembre (307 días), así que no se compara con años completos.
- **La serie no es homogénea:** la caída de 81 % y el vacío del medio de reporte hasta 2020 apuntan a un cambio de cobertura del registro, cuya causa no está documentada en el dataset.
- **Reportes, no accidentes:** el 88 % de las filas no tiene tipo de accidente (negativo, sin dato o «No aplica»).
- **Campos con muchos vacíos:** *numero_vehiculos* es nulo en 52,4 % (su disponibilidad va de 31,9 % en 2023 a 57,6 % en 2020), *medio_reporte* en 77,7 % y *direccion_reporte* en 49,5 %. Nada de esto se imputa.
- **Dos sistemas de origen:** el código de reporte llega en dos formatos (357.599 numéricos y 13.399 con prefijo AI) que no se comportan igual (47,9 % vs. 40,2 % traen número de vehículos).
- **Texto dañado:** 1.054 direcciones conservan un «?» donde debía ir una tilde o una eñe; no se reparan porque una regla global arreglaría unas y rompería otras.
- **Sin claves foráneas en el motor:** la integridad referencial se valida en el ETL y después de cargar, pero PostgreSQL no la impone.
- **Variables ausentes:** el dataset no trae hora ni coordenadas, por lo que no permite análisis espacial fino ni por franja horaria.

Próximos pasos

- Validar con la entidad que publica el dataset si hubo un cambio de sistema o de criterio de registro alrededor de 2020-2021.
- Definir un indicador de **accidente confirmado** (por ejemplo, excluir los reportes negativos) y rehacer las series con ese subconjunto para comprobar si la caída persiste.
- Comparar volúmenes con «reportes por día cubierto» y limitar las comparaciones anuales a años completos (2016-2023).
- Cruzar con fuentes externas (parque automotor, población) para pasar de conteos a tasas, en especial para la motocicleta.
- Para las siguientes entregas (P2/3 y P4), tratar 2016-2019 y 2020-2024 como regímenes distintos al construir variables, y no mezclar ambos periodos en promedios.